

## ТЕОРИЯ ЯЗЫКОВ ПРОГРАММИРОВАНИЯ

3 лабы, уже есть в ЛК (или где-то там). Для третьей уже есть файлы с вариантами (она объемная), на первую и вторую вариантов нет, делаем все задания. На практиках решаем задачи, за выходы к доске дают баллы, на последней практике контрольная с теми же задачами по типу, доп баллы будут учитываться только в счет автомата по контрольной. Максимум за контрольную 20 баллов, из них 10 максимум дополнительных. Всего можно набрать 95 баллов, набираешь 90 и контрольная минимум 10 баллов – пятерка, на остальные оценки: на 4 больше 80, на 3 больше 65, контрольная не учитывается. На лабы желательно приходить с готовыми лабами. Дальше впредь писать было сори

## **ЛЕКЦИЯ 1**

3 группы ЯП:

- 1) Машинный – набор команд, который интерпретируется на аппаратном уровне
- 2) Языки Assembler – языки низкого уровня – отображают команды некоторой машины
- 3) Языки высокого уровня – имеют сложную структуру, не зависят от ОС и набора команд.

Транслятор – обслуживающая программа, преобразующая исходную программу, представленную на входном ЯП, в рабочую программу, представленную на объектном языке.

## Основные виды трансляторов:

- *Assembler*
- *Компилятор*
- **Интерпретатор**

Их модификации

- Эмулятор
- Перекодировщик
- Макропроцессор

Ассемблер – системно обслуживающая программа, которая преобразует символические конструкции в команды машинного языка. Ассемблер предназначен для лучшего восприятия машинных команд. Заменяет 1 машинный код 1 командой

Компилятор – обслуживающая программа, выполняющая трансляцию на машинный язык программы, написанной на исходном языке программирования. Компилятор может заменять до 100 машинных команд одной командой.

Интерпретатор - программа или устройство, осуществляющая пооператорную трансляцию и выполнение исходной программы. Не порождает программы на машинном языке, программа выполняется в 50-100 раз медленнее чем на машинных кодах.

**Любой язык программирования имеет**

- **Алфавит**
- **Лексику**
- **Операторы**
- **Семантику**
- **Прагматизм**
- **Семиотику**

**Фазы трансляции**

- 1. Лексический анализ**
- 2. Синтаксический анализ**
- 3. Семантический анализ**
- 4. Синтез объектной программы**
- 5. Генератор кода**
- 6. Анализатор ошибок**

Лексический анализ – перевод исходной программы на внутренний язык компилятора (выделение лексем)

Синтаксический анализ – переводит последовательность образов лексем в форму промежуточной программы, которая более четко отражает структуру исходной (т.е. порядок и связь между операторами)

Семантический анализ – проверка семантических соглашений в программе

Синтез объектной программы – начинается с выделения и распределения памяти для основных объектов, анализируется каждое предложение исходной программы и генерируется семантически эквивалентное предложение объектного языка

Генератор кода - развертывает атомы, построенные синтаксическим анализатором в последовательность команд, которые выполняют соответствующие действия

Анализатор ошибок - получает информацию об ошибках, формирует сообщение пользователей и выполняет действия, связанные с корректным завершением работы программы в случае, когда дальнейшая трансляция невозможна.

Многопроходная организация - при ней каждая фаза является независимым процессом, передающем управление следующей фазе только после окончания обработки своих данных.

Однопроходная организация – при ней все фазы представляют единый процесс и передают друг другу данные небольшими фрагментами.

## Варианты взаимодействия блоков транслятора

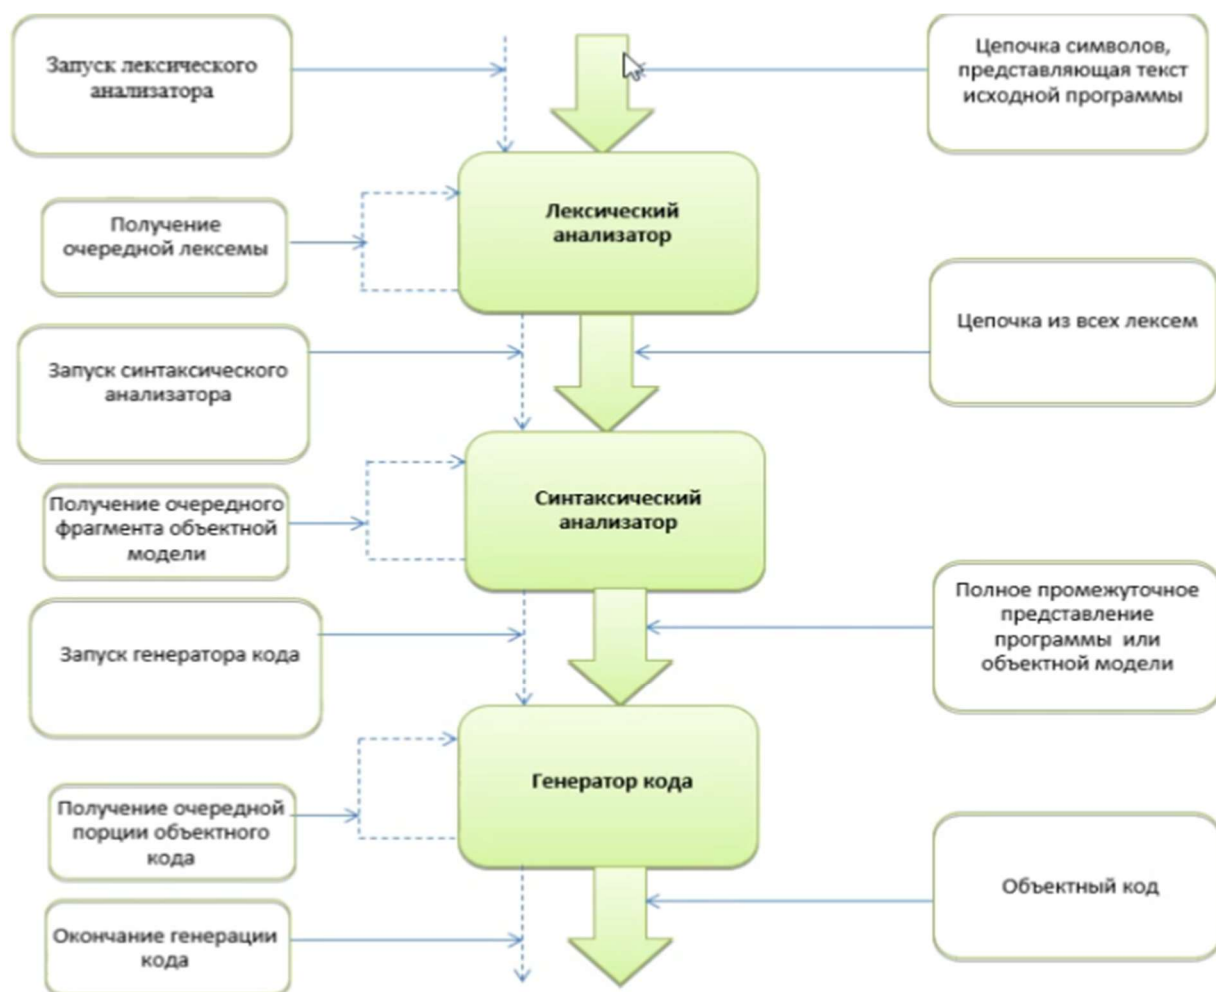
Выделяют два основных варианта взаимодействия:

- Многопроходная организация
- Однопроходная организация

На основе двух основных вариантов возможны различные сочетания.

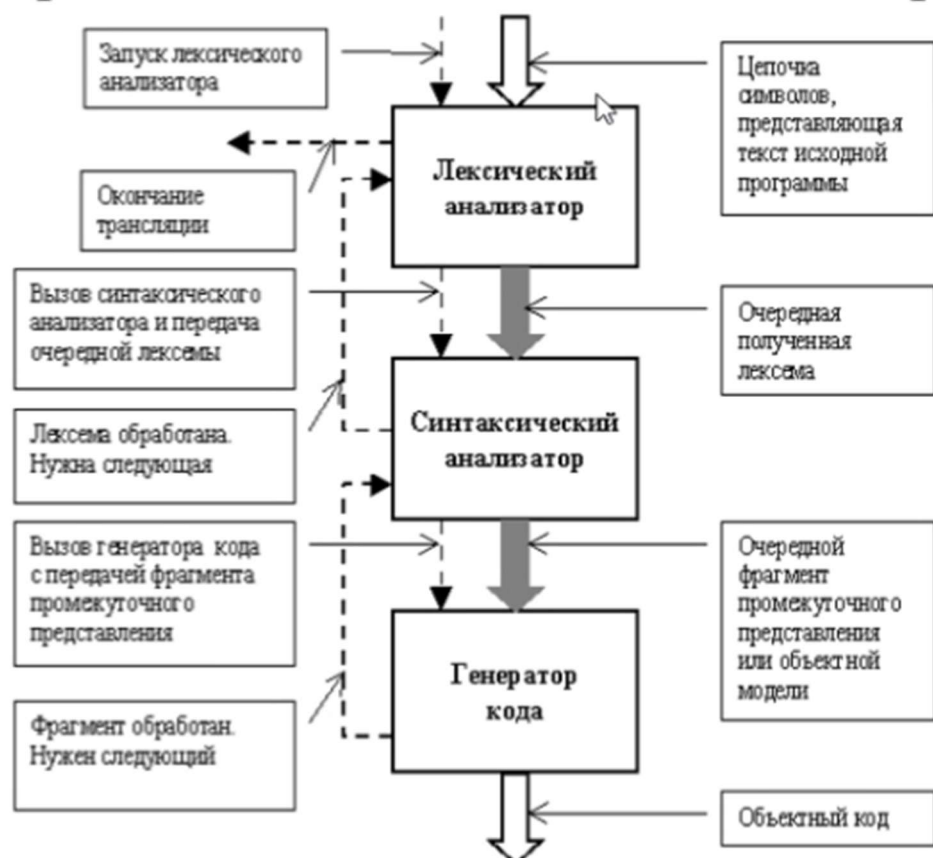
Многопроходная организация на примере компилятора:



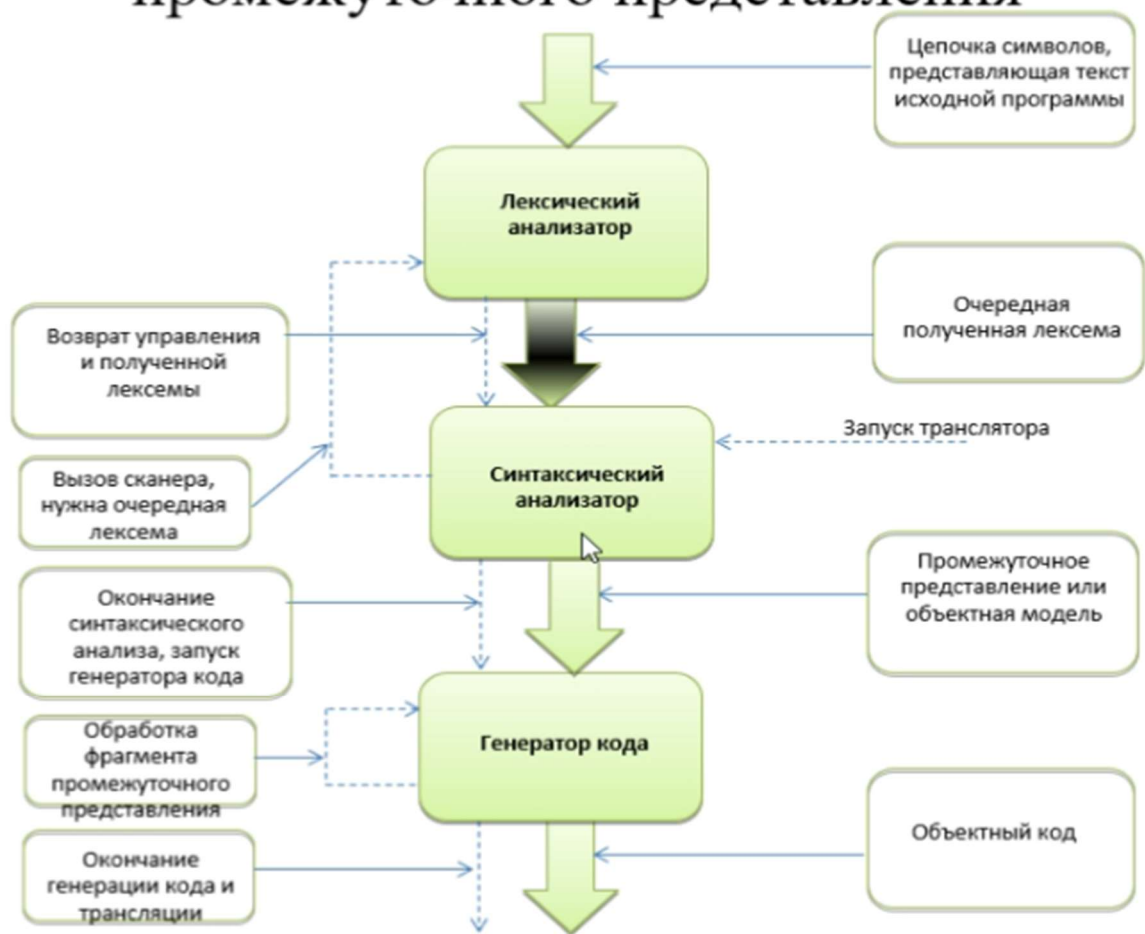


## 2. Однопроходное взаимодействие

### а) При управлении лексическим анализатором



## Двухпроходная схема с генерацией полного промежуточного представления



Формальный язык – множество цепочек конечной длины в алфавите  $A$ , задаваемое некоторым множеством правил

Механизм порождения позволяет описывать языки с помощью системы правил, называемых грамматикой.

Замыкание алфавита (итерация) – множество всех возможных цепочек над алфавитом.



# Формальные языки и грамматики

- Пусть  $A$ -алфавит

$$A_n = A \times A \times \dots \times A$$

$a_1 a_2 a_3 a_4 \dots a_n$  – цепочки

$(a_1, a_2, a_3, a_4, \dots, a_n)$  – так нельзя

- При  $n=1$ , буквы также являются цепочками.
- Цепочка, не имеющая букв, называется **пустой**, обозначается  $\lambda$ , не принадлежит алфавиту.
- **Замыкание** или **итерация** алфавита  $A$ , обозначают  $A^*$ :

$$A^* = A^0 \cup A^1 \cup \dots = \bigcup_{n=0}^{\infty} A^n, \text{ где } A^0 = \{\lambda\}, A^1 = A$$

(число нулей всегда равно числу единиц, если одинаковый индекс)

## Формальные языки и грамматики

Использование системы множеств:

$$L = \{0^n 1^n | n \geq 0\}$$

Примеры синтаксисов:

1)  $\{a^n b^n c^n | n \geq 0\}$

2)  $\{a^m b^n | m, n \geq 0\}$

3)  $\{x^n | n - \text{простое число}\}$

4)  $\{a^m b^n c^p | m=n \text{ или } n=p\}$

5)  $\{a^n b^n a^n | n > 0\}$

Примеры (картинка выше):

1) aaabbbccss,  $n = 3$ ;

2) aaabb,  $m = 3, n = 2$ ;

3) xxxxx,  $n = 5$ ;

4) aaabbcc,  $m = 3, n = 2, p = 2$ ;

5) aabbaa,  $n = 2$ ;

## Формальные языки и грамматики

- Множество непустых цепочек над алфавитом  $A$  называется **усеченной итерацией**:

$$A^+ = \bigcup_{n=1}^{\infty} A^n = A^* \setminus \{\lambda\}$$

Каждая цепочка  $\alpha \in A^*$  имеет конечную длину  $|\alpha|$ , при чем  $|\lambda| = 0$

- Пусть  $\alpha, \beta \in A^*$  принадлежат алфавиту. Цепочка  $\beta$  называется **подцепочкой**  $\alpha$ , если  $\alpha = \gamma\beta\delta$ , причем  $\gamma, \delta \in A^*$

(если справа и слева от буквы есть символы, причем принадлежащие алфавиту  $A$ , если над  $A$  снежинки (\*) – туда могут входить пустые цепочки, если (+) – любые кроме пустых)

- Язык  $L$  над алфавитом  $A$**  – это множество цепочек итераций алфавита  $A^*$
- Получается  $L \subseteq A^*$ , отсюда:

$$L^0 = \{\lambda\}$$

$$L^n = L^{n-1} \cdot L, \quad n \in \mathbb{N}$$

$$L^+ = \bigcup_{n=1}^{\infty} L^n$$

$$L^* = \bigcup_{n=0}^{\infty} L^n$$



Формальной порождающей грамматикой  $G$  называется четверка  $G = \langle N, T, P, S \rangle$ ,

где  $V = T \cup N$ ,  $T \cap N = \{\emptyset\}$

$$S \in N$$

$P$  – продукция вида  $\alpha \rightarrow \beta$ ,

где

$$\alpha \in (T \cup N)^* \cdot N (T \cup N)^* = V^+$$

$$\beta \in (T \cup N)^* = V^*$$

Терминалы  $a, b, c, \dots$ , либо  $0, 1, \dots, 9$ .

Нетерминалы:  $A, B, C, D, S$ .

Цепочки произвольной длины:  $\alpha, \beta, \gamma, \delta$

Пустая цепочка:  $\lambda$

$N$  – конечное непустое множество **нетерминальных** символов

$T$  – конечное непустое множество **терминальных** символов

$S$  – символ из множества  $N$ , называемый начальным

$P$  – конечное множество правил (продукций) грамматики

Вывод – последовательность подстановки.

**Пример:** Грамматикой, генерирующей язык,  
задаваемый синтаксисом  $L = \{0^n 1^n \mid n \geq 0\}$ , является:

$$G = \{N, T, P, S\}, \quad N = \{S\}, \quad T = \{0, 1\}, \quad S = \{S\},$$

$$P = \{ 1. S \rightarrow 0S1$$

$$2. S \rightarrow \lambda \}$$

Выводы цепочек:

$$S \xrightarrow{1} 0S1 \xrightarrow{1} 00S11 \xrightarrow{2} 0011 \quad (n=2)$$

$$S \xrightarrow{2} \lambda \quad (n=0)$$



**Пример:**  $G = \{N, T, P, S\}$

$T = \{\text{дом, дуб, старый, заслоняет}\}$

$N = \{\text{Предложение, Подлежащие, Сказуемое, Дополнение, Прилагательное, Существительное}\}$

$S = \{\text{Предложение}\}$

$P = \{1. \text{Предложение} \rightarrow \text{Подлежащие Сказуемое Дополнение}$

2. Подлежащие  $\rightarrow$  Прилагательное Существительное

3. Дополнение  $\rightarrow$  Прилагательное Существительное

4. Сказуемое  $\rightarrow$  заслоняет

5. Прилагательное  $\rightarrow$  старый

6. Существительное  $\rightarrow$  дом

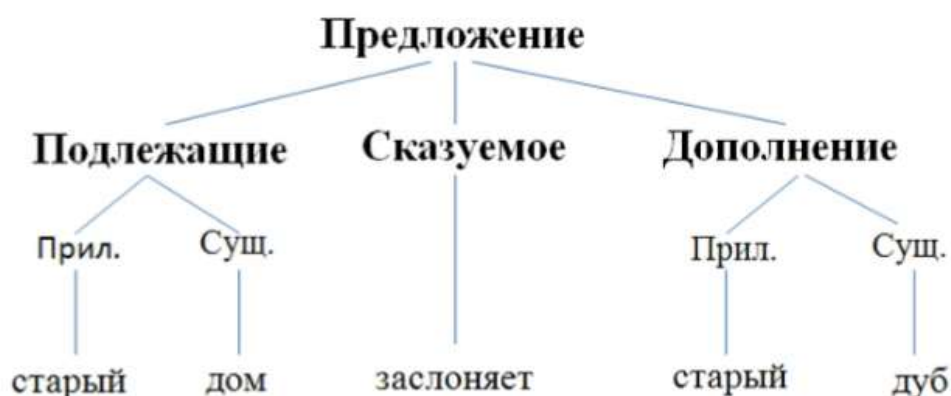
7. Существительное  $\rightarrow$  дуб}

**Вывод цепочки:**

Предлож.<sup>1</sup> $\rightarrow$ Подл. Сказ. Допол.<sup>2</sup> $\rightarrow$ Прил. Сущ. Сказ.

Допол.<sup>3</sup> $\rightarrow$ Прил. Сущ. Сказ. Прил. Сущ.<sup>5</sup> $\rightarrow$ старый Сущ.

Сказ. старый Сущ.<sup>6,7</sup> $\rightarrow$ старый дом Сказ. старый дуб  $\xrightarrow{4}$   
старый дом заслоняет старый дуб



Рассмотрим грамматику  $G = (\{a, b, c, \lambda\}, \{S, A, B\}, P, S)$

$P = \{$

1.  $S \rightarrow aABc$
2.  $S \rightarrow \lambda$
3.  $A \rightarrow cSB$
4.  $A \rightarrow Ab$
5.  $B \rightarrow bB$
6.  $B \rightarrow a$


Пусть дана цепочка  $aABc$ , тогда цепочка  $acabac$  может иметь след. вывод:

1            4            3            2            6            6  
 $S \rightarrow aABc \rightarrow aAbBc \rightarrow acSBbBc \rightarrow acBbBc \rightarrow acabBc \rightarrow acabac$

$S \Rightarrow^* acabac$

(если мы поставили \*, значит мы когда-то смогли вывести упоминаемую цепочку, удобно, когда делается много однотипных действий с одинаковыми шагами)

Дерево вывода терминальной цепочки  $acabac$



Левый или левосторонний вывод  $\alpha \rightarrow_L \beta$

Правый или правосторонний вывод  $\alpha \rightarrow_R \beta$

# Классификация грамматик и языков по Хомскому

**0 – класс:** правила вывода  $P$  грамматики  $G$  имеют форму  $\varphi \rightarrow \omega$ , без каких-либо ограничений на строки  $\alpha \rightarrow \beta$ .

**1 – класс:** все элементы множества  $P$  имеют форму  $\varphi \rightarrow \omega$ ,

где  $\varphi = \varepsilon_1 \alpha \varepsilon_2$ ,  $\omega = \varepsilon_1 \beta \varepsilon_2$ ;  $\varepsilon_1, \varepsilon_2 \in V^*$ ,  $\alpha \in N$ ,  $\beta \in V^+$ .

**контекстно-зависимая грамматика (КЗ)**

если  $(|\varphi| \leq |\omega|)$ , то не укорачивающая грамматика

## Иерархия языков, грамматик и автоматов

3) Контекстно-зависимая грамматика (класс 1)

$G_4 = \{ \{B, C, S\}, \{a, b, c\}, P, S \}$

$P:$   $\left\{ \begin{array}{l} 1. S \rightarrow aSBC \\ 2. S \rightarrow abc \\ 3. cB \rightarrow Bc \\ 4. bB \rightarrow bb \\ 5. bC \rightarrow bc \\ 6. cC \rightarrow cc \end{array} \right\}$

$S^1 \rightarrow aSBC^2 \rightarrow aabcBC^3 \rightarrow aabBcC^{4,6} \rightarrow aabbcc$

$L(G) = \{ a^n b^n c^n, n \geq 1 \}$

**2 – класс:** все порождающие правила имеют вид  $A \rightarrow \beta$ , где  $A \in N$ ,  $\beta \in V^+$ .

**контекстно-свободная грамматика (КС)**

если  $\beta \in V^*$ , то **укорачивающая КС-грамматика**.

**3 – класс:** все порождающие правила имеют вид  $A \rightarrow bB$ ,  $A \rightarrow b$ , где  $A$  и  $B \in N$ ,  $b \in T$

**автоматные или А-грамматики**

Теорема №1:  $L(G)$  легко распознаваем

Теорема №2:  $L(G) \setminus \lambda$  является языком класса 0

2) Контекстно-свободная грамматика (класс 2)

$G_3 = \{ \{E, T, F\}, \{a, +, *, (, )\}, P, E \}$

P: 
$$\left\{ \begin{array}{l} 1. E \rightarrow T \\ 2. E \rightarrow E + T \\ 3. T \rightarrow F \\ 4. T \rightarrow T * F \\ 5. F \rightarrow (E) \\ 6. F \rightarrow a \end{array} \right\}$$

$E^2 \rightarrow E + T^1 \rightarrow T + T^3 \rightarrow F + F^6 \rightarrow a + a$

$L(G) = \{ \text{арифметические выражения} \}$

# Иерархия языков, грамматик и автоматов



## Способы записи синтаксиса языка

### 1. Метаязык Хомского

- $\rightarrow$  отделяет левую часть правила от правой.
- Нетерминалы обозначаются буквами  $A_i$ , где  $i$  – номер нетерминала.
- Терминалы – это символы, используемые в описываемом языке.

- Описание идентификатора:

$$1. A_1 \rightarrow A \quad 52. A_1 \rightarrow z$$

$$2. A_1 \rightarrow B \quad 53. A_2 \rightarrow 0$$

.....

$$26. A_1 \rightarrow Z \quad 62. A_2 \rightarrow 9 \quad 64. A_3 \rightarrow A_3 A_1$$

$$27. A_1 \rightarrow a \quad 63. A_3 \rightarrow A_1 \quad 65. A_3 \rightarrow A_3 A_2$$

### 2. Метаязык Хомского-Щутценберже

- $=$  отделяет левую часть правила от правой.
- Нетерминалы обозначаются буквами  $A_i$ , где  $i$  – номер нетерминала.
- Терминалы – это символы, используемые в описываемом языке.

- Описание идентификатора:

$$1. A_1 = A + B + \dots + Z + a + \dots + z$$

$$2. A_2 = 0 + 1 + 2 + \dots + 9$$

$$3. A_3 = A_1 + A_3 A_1 + A_3 A_2$$

### 3. Формы Бэкуса-Наура (БНФ)

- $::=$  отделяет левую часть правила от правой.
- Нетерминалы обозначаются произвольной символьной строкой, заключенной в  $< >$ .
- Терминалы – это символы, используемые в описываемом языке.
- Описание идентификатора:
  1.  $\langle \text{буква} \rangle ::= A | B | C | \dots | Z | a | \dots | z$
  2.  $\langle \text{цифра} \rangle ::= 0 | 1 | 2 | \dots | 8 | 9$
  3.  $\langle \text{идентификатор} \rangle ::= \langle \text{буква} \rangle | \langle \text{идентификатор} \rangle \langle \text{буква} \rangle | \langle \text{идентификатор} \rangle \langle \text{цифра} \rangle$

### 4. Расширенные форма Бэкуса-Наура (РБНФ)

- $[ ]$  синтаксическая конструкция может отсутствовать
- $\{ \}$  повторение (возможно от 0 раз)
- $( )$  ограничение альтернативных конструкций
- $\{ / \}$  повторение 1 и более раз.
- **Нетерминалы** – изображаются словами, на русском языке.
- **Терминалы** – это слова, написанные буквами латинского алфавита или цепочками знаков, заключенных в кавычки.



- \$ ставится в начале правила.
- Каждое правило заканчивается точкой.
- = отделяет левую часть правила от правой.
- | альтернативы.
- Если нетерминал состоит из нескольких слов, то они пишутся слитно.
- Описание идентификатора:

\$буква =  
 "A"|"B"|"C"|"D"|"E"|"F"|"G"|"H"|"I"|"J"|"K"|"L"|"M"|"N"|  
 "O"|"P"|"Q"|"R"|"S"|"T"|"U"|"V"|"W"|"X"|"Y"|"Z".

\$цифра = "0"|"1"|"2"|"3"|"4"|"5"|"6"|"7"|"8"|"9".

\$идентификатор = буква { буква | цифра }.





